


Chicago Crimes: Uçtan Uca Büyük Veri & ML Pipeline


Kafka, Spark Streaming ve Delta Lake
üzerinde çalışan, konteynerize edilmiş
streaming tabanlı suç tipi tahmin motoru.

Takım: Emre Aytaş, Hatice Kübra Kılıçaslan,
Berker Yiğit, Mertcan Kuzey
Tarih: Bahar 2026



Veriden Öngörüye: Görev Tanımı

2001'den günümüze toplanan Chicago polis verilerini kullanarak, olay anındaki zaman, konum ve bağlam bilgilerinden Suç Tipini (Primary Type) tahmin etmek.



~7.9 Milyon

(Ham Olay Kaydı / 22 Kolon)

12 Adet

(Türetilmiş ML Özelliği)


Top-5 + 1

(Sınıflandırma Hedefi - Aşırı dengesiz veri setini optimize etmek için Top-5 suç tipi ve birleştirilmiş OTHER kategorisi)

Sadece statik bir analiz değil; **Kafka** üzerinden akan **canlı bir veri akışını yakalayan, işleyen** ve eğiten kesintisiz, **konteynerize** bir sistem kurmak.


Sistem Mimarisi: Konteynerize ve İzole

Tek bir docker-compose up komutuyla ayağa kalkan,
Zookeeper bağımlılığı olmayan (KRaft) 7 servisli mikro mimari.




Veri Yutma: Kesintisiz Kafka Akışı

Ham CSV verisi satır satır okunarak JSON formatında Kafka'ya iletilir. Sistem, gerçek dünya senaryolarını simüle etmek için 3 farklı hız modunda tasarlanmıştır.



Delta Lake: Medallion Veri Rafinerisi



- Kafka JSON mesajlarının ham haliyle Delta'ya append edilmesi.
- **Kritik Karar:** Micro-batch çökmesini önlemek için `maxOffsetsPerTrigger=200K` sınırı uygulandı. `partitionBy(event_date)`.

- id bazlı deduplikasyon, null filtreleme (koordinat/tip) ve zaman türetmeleri (saat, gün, ay).
- **Kritik Karar:** Fan-out darboğazını aşmak için `partitionBy(event_year)` (sadece 28 dizin) kullanıldı ve **Delta OPTIMIZE** çalıştırıldı.



- ML ve analitik için özelleşmiş görünüm: `type_stats`, `district_stats`, `hourly_stats`.
- Modele giren son `feature_view`.

Keşifsel Veri Analizi (EDA): Sinyalleri Yakalamak

Insight Panel 2:


Zamanın Etkisi: Analizler, **Theft** suçlarının genellikle öğleden sonra zirve yaparken, **Battery** vakalarının gece yarısı civarında gösterdiğini kanıtladı.

Yıllık Suç Eğilimi



Insight Panel 3:

Bağlam ve Tutuklama: Toplam vakaların %21.06'sı tutuklama ile sonuçlanıyor. **arrest** ve **domestic flag**'leri, ML modeli için güçlü ayırt edicilerdir.




Insight Panel 1:

Sınıf Dengesizliği: THEFT açık ara en yaygın olanıdır. Uzun kuyruk problemi, veri setinin **Top-5 + OTHER** olmak üzere 6 dengeli sınıfa indirgenmesini zorunlu kılmıştır.

Özellik Mühendisliği: ML Yakıtı

Ham verilerden, sınıflandırma gücü yüksek 12 özellik türetilerek, VectorAssembler ile model hattına beslendi.




Model Arenası: 5 Algoritmanın Çarpışması

6 sınıflı (Top-5 + OTHER) hedef için en optimal algoritmayı belirlemek.

Model	Native Multi-class?	Mimari Yaklaşım	Model Gücü/Zayıflığı	Durum
Logistic Regression	Evet	Lineer Baseline	Zaman/konum korelasyonlarında zayıf.	Elendi
Naive Bayes	Evet	Olasılıksal	Özellik bağımsızlığı varsayımı nedeniyle isabetsiz.	Elendi
Decision Tree	Evet	Tek Ağaç	Hızlı fakat overfit riski barındırıyor.	Elendi
Gradient Boosted Trees	Hayır	OneVsRest Wrapper	N sınıf=N Binary model olarak sarmalandı. Çok yavaş.	Elendi
Random Forest	Evet	Ağaç Topluluğu	Kategorik ve koordinat verisini harmanlamada en başarılı; %45.3 Accuracy.	Kazanan


Kazanan Modelin Anatomisi: Random Forest

Özellik Önemi (Feature Importance)



Karar Mekanizması: Model, tahmin yaparken en çok Konum ve Zaman metriklerine ağırlık verdi. Ağaç yapısı (50 tree, 10 depth) bu non-lineer ilişkileri başarıyla böldü.

Karmaşıklık Matrisi (Confusion Matrix)



Performans Analizi: Tanımı geniş OTHER kategorisi en fazla karmaşıklığı yaratırken, karakteristiği belirgin suçlar keskin şekilde ayrıştı.

Accuracy: ~45.37% | Weighted F1: ~0.38
(6 sınıflı, aşırı dengesiz gerçek hayat verisi için sağlam bir baseline)

İzlenebilirlik ve Kayıt: MLflow Entegrasyonu

Eğitim süreci izole bir deney olmaktan çıkarılıp, SQLite veritabanı destekli lokal bir MLOps yaşam döngüsüne dönüştürüldü.

Parametre Takibi:

Sınıf sayısı, sample fraction, ağaç derinliği, numTrees otomatik loglanır.

Artifact Saklama:


Feature Importance CSV, Confusion Matrix, ve Sınıf bazlı raporlar depolanır.

Metrik Loglama:

Accuracy, Weighted F1, Precision, Recall AUC-OvR-Macro, ve Eğitim Süresi.


Model Registry:

En başarılı model chicago-crime-classifier etiketiyle etiketiyle canlı çıkarım için kaydedilir.



Orkestrasyon: Tek Tuşla Uçtan Uca Kurulum

Sistemin tam tekrarlanabilirliği (reproducibility) için 11 aşamalı tam otomatik bash orkestrasyonu tasarlanmıştır.



Son Kullanıcı Arayüzü: Streamlit Dashboard

Arka planda çalışan kompleks Delta tabloları ve Spark işleri, Delta Python client üzerinden son kullanıcıya gecikmesiz sunulur.


Genel Tablo:

Toplam suç grafikleri, tutuklama ve aile içi şiddet oranları.



3. Saat Heatmap:

Saat x Suç tipi yoğunluk haritası.




2. İlçe Analizi:

İlçe bazında suç frekansları ve en sık karşılaşılan suç tipleri.





5. MLflow Liderlik Tablosu:

Eğitilen 5 modelin parametre ve başarımlarının karşılaştırması.



4. Tahminler:

En iyi modelin örneklem üzerindeki canlı tahminleri ve doğruluk oranı.



Mühendislik Kararları ve Darboğaz Çözümleri

! Sorun !

Sorun: Bronze streaming tek bir dev `micro-batch`'te çöküyor ve Delta log'a commit atamıyordu.

Sorun: Silver katmanında `partitionBy(event_date)` yüzünden 67.000+ minik Parquet dosyası oluştu (Fan-out hell).

Sorun: Spark MLlib GBTCClassifier algoritması `native` olarak çoklu sınıf desteklemiyordu.

✓ Çözüm ✓

Çözüm: Okuma mekanizmasına `maxOffsetsPerTrigger=200K` sınırı eklendi. Sınırsız batch yerine her ~5 saniyede bir güvenli commit atması sağlandı.

Çözüm: Bölümleme stratejisi `event_year` (sadece 28 `dizin`) olarak değiştirildi. Delta `OPTIMIZE` komutuyla dosyalar sıkıştırıldı.

Çözüm: N Sınıf = N Binary Problem mantığıyla çalışan `OneVsRest` sarmalayıcısı (wrapper) entegre edildi.

Sentez: Kesintisiz Veri Yaşam Döngüsü

Impact
(Streamlit)

Intelligence
(Spark ML,
MLflow)

Infrastructure
(Docker, Kafka KRaft)

Processing & Storage
(Spark, Delta Lake Medallion)

Özet

Chicago Crimes sistemi, ham sensör verisini akış halinde yutan, temizleyen, özellik mühendisliği yapan, algoritmaları yarıştıran ve zekayı görselleştiren kurumsal seviyede bir veri ürünüdür.

Temel Kazanımlar

- Zookeeper'sız Kafka (KRaft) ile modern stream mimarisi.
- Aynı Delta Lake üzerinde Streaming (Bronze) ve Batch (Silver/Gold) süreçlerinin ACID garantisiyle birleştirilmesi.
- Lokal SQLite ve tam izlenebilirlik ile uçtan uca MLOps pratiği.